R2-A1-S10 Redes Neuronales V

Edward Alexander Moreno Matallana

Universidad de Cundinamarca UCUNDINAMARCA

Especialización en Inteligencia Artificial

Programa

2026

OBJETIVO

Evaluar el comportamiento de un codificador (encoder) entrenado con rostros sintéticos al procesar fotografías reales, mediante el análisis de métricas de distancia euclidiana, similitud coseno y técnicas de aprendizaje few-shot, con el fin de identificar las limitaciones derivadas de la transferencia de datos sintéticos a entornos reales.

Informe de práctica: Redes Neuronales V

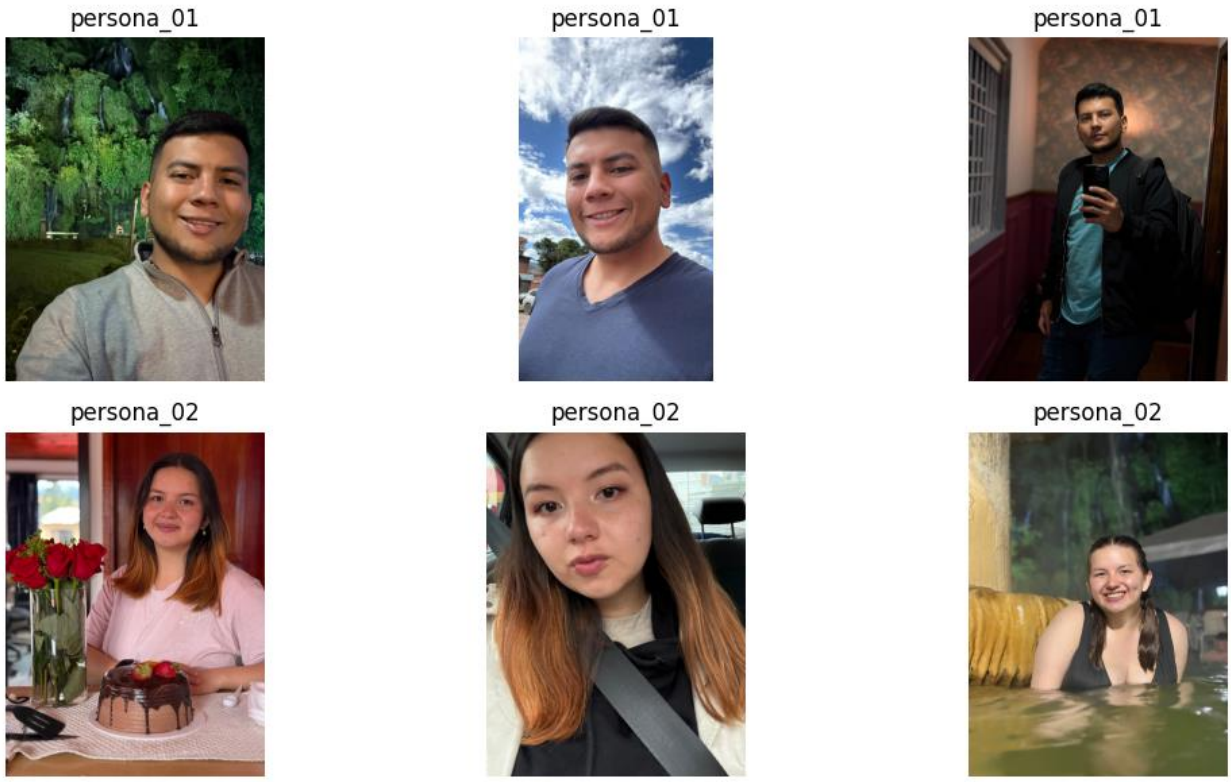
Pasos 1 al 8. Organización, carga y preprocesamiento de fotografías

En esta etapa organicé las seis fotografías en carpetas separadas por persona, de acuerdo con la estructura propuesta en la guía.

Posteriormente, preparé las imágenes mediante conversión a escala de grises y ajuste de sus dimensiones a 64 × 64 píxeles. Este procedimiento permitió mantener un formato uniforme para que las fotografías pudieran ser procesadas por el encoder convolucional.

También se realizó la normalización de los valores de los píxeles, dividiéndolos entre 255 para llevarlos al intervalo de 0 a 1.

El preprocesamiento es importante porque permite que todas las imágenes tengan las mismas dimensiones y características de entrada, independientemente de su resolución original.



Paso 9. Convertir las seis fotografías a tensores

La conversión permitió organizar las seis fotografías en un tensor con la estructura requerida por la red neuronal.

El resultado obtenido fue:

[6, 1, 64, 64]

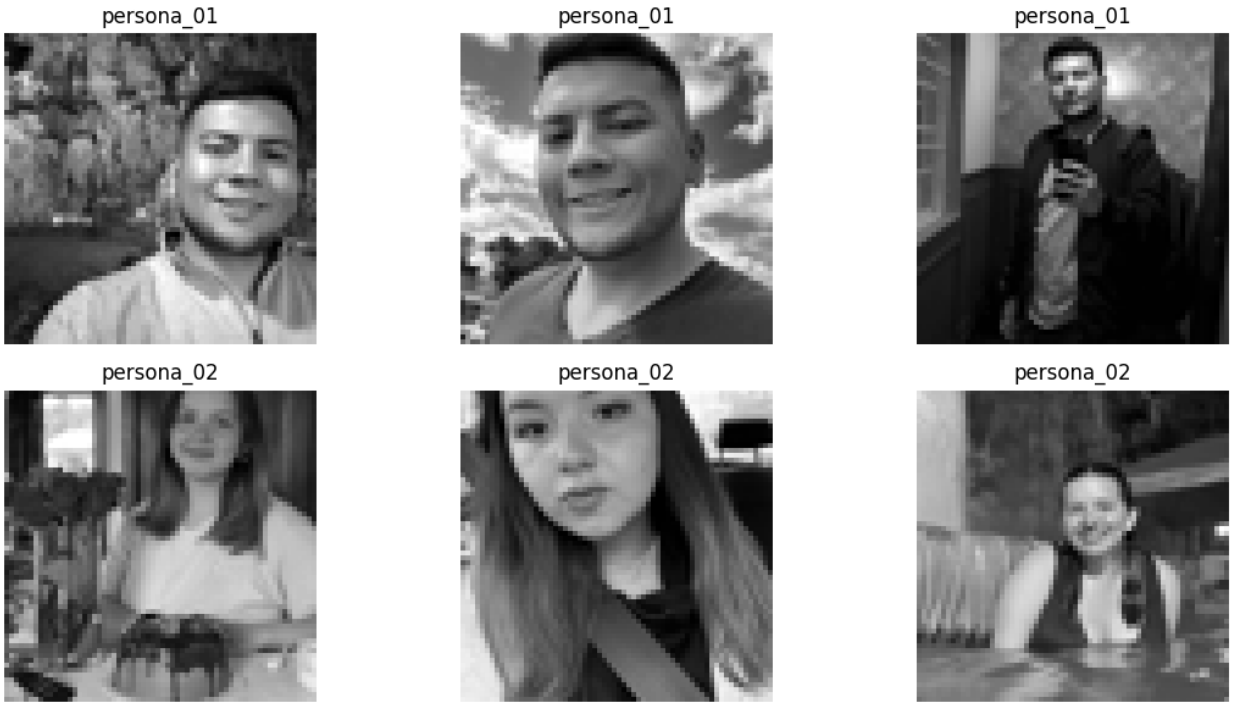
Esta estructura representa seis imágenes, un canal de escala de grises y dimensiones de 64 × 64 píxeles.

Las etiquetas permitieron diferenciar las imágenes correspondientes a cada persona, utilizando los valores internos 0 y 1.

Paso 10. Visualizar las fotografías procesadas

En este paso comprobé visualmente las imágenes después del preprocesamiento. La visualización permitió verificar que los rostros conservaran sus características principales y que las imágenes estuvieran disponibles en el formato esperado por el modelo.

Considero que esta etapa es importante porque un recorte inadecuado, una iluminación deficiente o una posición demasiado diferente pueden afectar la calidad de los embeddings generados.



Paso 11. Seleccionar Anchor, Positive y Negative

Pregunta: ¿Por qué Positive no debe ser exactamente la misma foto que Anchor?

Positive no debe ser exactamente la misma fotografía que Anchor porque el objetivo es que la red compare las características de una misma identidad en diferentes capturas.

Si se utilizara la misma imagen, el modelo podría limitarse a comparar representaciones prácticamente idénticas, sin demostrar que es capaz de reconocer características que permanecen estables entre distintas fotografías.

Por esta razón, utilicé dos fotografías diferentes de Persona 1 para Anchor y Positive, y una fotografía de Persona 2 para Negative.



Paso 12. Visualizar el triple real

En este paso verifiqué visualmente que Anchor y Positive correspondieran a la misma persona y que Negative perteneciera a una persona diferente.

Esta comprobación permite validar que la tripleta esté correctamente construida antes de realizar las comparaciones matemáticas.

Paso 13. Generar los tres embeddings

El encoder transformó las tres fotografías en representaciones vectoriales de 64 dimensiones.

Cada imagen produjo un tensor de forma [1,64], lo que significa que cada fotografía quedó representada mediante un vector de 64 características.

A partir de estos embeddings fue posible realizar las comparaciones de distancia y similitud sin trabajar directamente con los píxeles originales.

Paso 14. Observar algunos valores de los embeddings

En este paso observé los primeros diez valores de cada embedding. Los resultados corresponden a números decimales que representan características aprendidas por el encoder.

No es necesario interpretar cada dimensión de manera independiente, porque el significado de los embeddings se encuentra principalmente en la relación geométrica entre los vectores.

Por esta razón, el análisis se concentra en las distancias y similitudes obtenidas entre las diferentes fotografías.

Paso 15. Normalizar los embeddings

La normalización L2 permitió ajustar los embeddings para que todos tuvieran una longitud igual a uno.

Este procedimiento reduce el efecto de las diferencias de magnitud entre vectores y permite realizar comparaciones basadas principalmente en su dirección.

La normalización es especialmente importante cuando se utiliza la similitud coseno como medida de comparación.

Paso 16. Calcular distancia euclidiana

Pregunta: ¿En tus resultados se cumple distancia_AP menor que distancia_AN? Explica qué significa.

En mi ejecución obtuve los siguientes resultados:

Comparación	Distancia euclidiana
Anchor–Positive	0.3017
Anchor–Negative	0.3176

Sí, se cumple que la distancia Anchor–Positive es menor que la distancia Anchor–Negative.

Esto significa que el embedding correspondiente a Anchor se encuentra ligeramente más cerca del embedding Positive que del embedding Negative. Por lo tanto, el modelo logró establecer el orden esperado entre las imágenes de la misma persona y las de personas diferentes.

Sin embargo, la diferencia entre ambas distancias es pequeña, por lo que considero que la separación obtenida no es suficientemente amplia para afirmar que el encoder distingue de manera robusta las dos identidades reales.

Paso 17. Interpretar automáticamente las distancias

El resultado de esta comparación fue favorable porque la distancia correspondiente a la misma persona fue menor que la distancia entre personas diferentes.

No obstante, es importante reconocer que el comportamiento fue limitado, debido a que la diferencia entre los valores fue de solamente 0.0159.

Esto demuestra que, aunque el encoder produjo un resultado favorable en esta tripleta, todavía existe una separación reducida entre las representaciones de las dos personas.

Paso 18. Calcular similitud coseno

Pregunta: ¿La similitud_AP resultó mayor que similitud_AN? Compara con lo que ocurrió usando distancia euclidiana.

Los resultados obtenidos fueron:

Comparación	Similitud coseno
Anchor–Positive	0.9545
Anchor–Negative	0.9496

Sí, la similitud Anchor–Positive fue mayor que la similitud Anchor–Negative.

Este resultado coincide con lo observado mediante la distancia euclidiana. En ambas mediciones, la relación obtenida fue favorable porque las fotografías de la misma persona presentaron una mayor cercanía entre sus representaciones.

Sin embargo, la diferencia entre las similitudes también fue reducida, con un valor de 0.0049.

Es importante comprender que ambas métricas expresan la relación entre los embeddings de manera diferente: en la distancia euclidiana los valores menores indican mayor proximidad, mientras que en la similitud coseno los valores mayores indican una mayor semejanza entre las direcciones de los vectores.

Paso 19. Generar embeddings normalizados para las seis fotografías

En este paso se generaron los embeddings correspondientes a las seis fotografías y se aplicó nuevamente la normalización L2.

Cada imagen quedó representada mediante un vector de 64 dimensiones, por lo que el resultado esperado y utilizado en el experimento fue una matriz de forma [6,64].

Esta representación permitió disponer de todas las fotografías en un mismo espacio vectorial y preparar los datos para construir los prototipos Few-shot.

Paso 20. Identificar las posiciones de cada persona

En esta etapa se identificaron las posiciones de las fotografías correspondientes a cada identidad.

La distribución utilizada fue:

- Persona 1: fotografías 1, 2 y 3.

- Persona 2: fotografías 1, 2 y 3.

Las dos primeras fotografías de cada persona se utilizaron como referencias, mientras que la tercera se reservó para la evaluación.

Esta separación permitió realizar las pruebas Few-shot sin utilizar las fotografías de consulta para construir los prototipos.

Paso 21. Construir el prototipo de Persona 1

Para construir el prototipo de Persona 1 utilicé los embeddings correspondientes a sus dos primeras fotografías.

Posteriormente, calculé el promedio de ambos vectores y apliqué normalización L2. El resultado fue un prototipo con 64 características, que representa matemáticamente las dos fotografías utilizadas como referencia.

Paso 22. Construir el prototipo de Persona 2

Realicé el mismo procedimiento con las dos primeras fotografías de Persona 2.

El resultado fue un segundo prototipo de 64 dimensiones, que permitió representar a esta persona dentro del espacio de embeddings.

Con ambos prototipos fue posible comparar las fotografías de prueba y determinar cuál presentaba mayor similitud coseno.

Paso 23. Probar la tercera fotografía de Persona 1

Pregunta: ¿Cuál fue la diferencia entre la similitud correcta y la similitud incorrecta? ¿Fue amplia o pequeña?

Los resultados obtenidos fueron:

Comparación	Similitud
Fotografía de Persona 1 con prototipo Persona 1	0.9823
Fotografía de Persona 1 con prototipo Persona 2	0.9857

La similitud con el prototipo de Persona 2 fue mayor que la similitud con su propio prototipo. Por esta razón, el modelo clasificó incorrectamente la fotografía de Persona 1 como Persona 2.

La diferencia entre ambas similitudes fue de 0.0034, por lo que considero que fue muy pequeña. Este resultado demuestra que el encoder no logró establecer una separación adecuada para esta fotografía de prueba.

Paso 24. Probar la tercera fotografía de Persona 2

Los resultados obtenidos fueron:

Comparación Similitud

Fotografía de Persona 2 con prototipo Persona 1 0.9744

Fotografía de Persona 2 con prototipo Persona 2 0.9232

En este caso, la similitud con el prototipo de Persona 1 fue superior a la similitud con el prototipo de Persona 2.

Por esta razón, el modelo clasificó incorrectamente la fotografía de Persona 2 como Persona 1.

Este resultado evidencia que el encoder presentó dificultades para diferenciar las identidades cuando se utilizaron fotografías reales.

Paso 25. Construir el resumen de la prueba Few-shot

Los resultados de las dos consultas fueron los siguiente

Fotografía evaluada	Identidad real	Predicción	Resultado
Fotografía de Persona 1	Persona 1	Persona 2	Incorrecto
Fotografía de Persona 2	Persona 2	Persona 1	Incorrecto

Ambas fotografías fueron clasificadas incorrectamente. Esto demuestra que el modelo no consiguió generalizar adecuadamente las representaciones aprendidas con datos sintéticos hacia las fotografías reales utilizadas en esta segunda práctica.

Paso 26. Calcular la precisión de la prueba

El cálculo de precisión fue:

$$\text{Precisión} = \frac{\text{Aciertos}}{\text{Total de consultas}} \times 100$$

En mi experimento se obtuvieron cero aciertos de dos consultas:

$$\text{Precisión} = \frac{0}{2} \times 100 = 0\%$$

Este resultado indica que ninguna de las dos fotografías reservadas fue clasificada correctamente mediante los prototipos Few-shot.

Considero importante conservar este resultado porque permite identificar las limitaciones del modelo y analizar la diferencia entre los datos sintéticos utilizados durante el entrenamiento y las fotografías reales utilizadas durante la evaluación.

Paso 27. Graficar las cuatro similitudes Few-shot

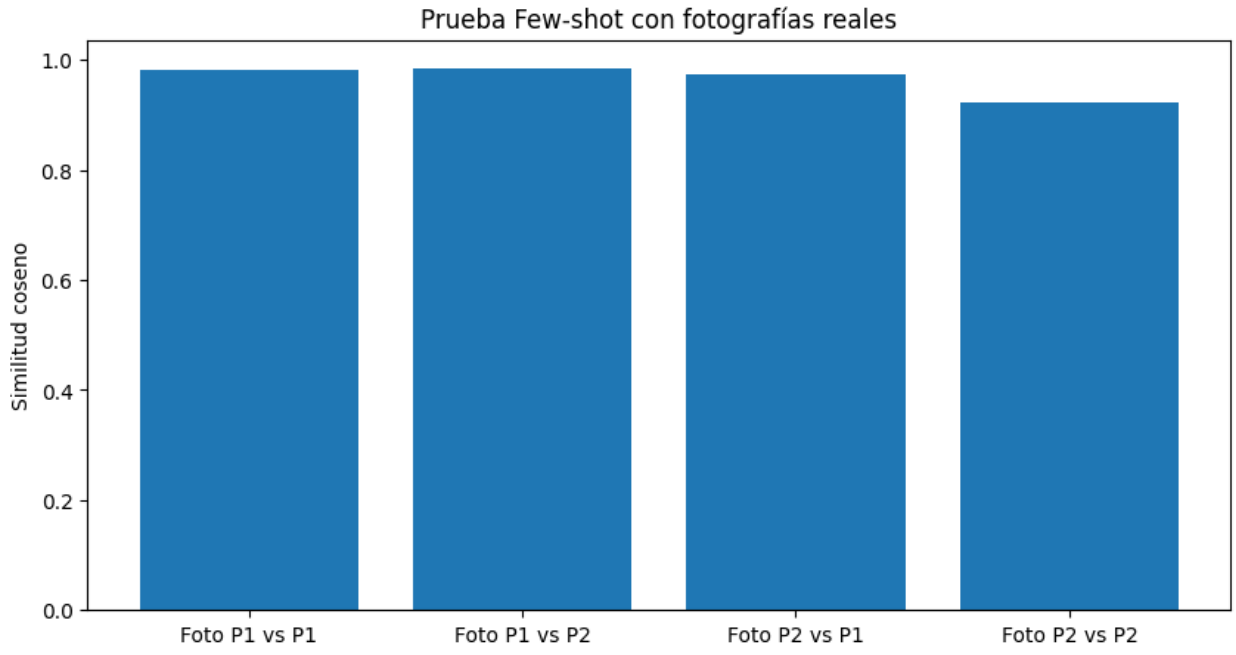
Pregunta: ¿La gráfica confirma las dos predicciones? Describe qué barras son mayores.

La gráfica permite observar las cuatro comparaciones realizadas entre las fotografías de prueba y los dos prototipos.

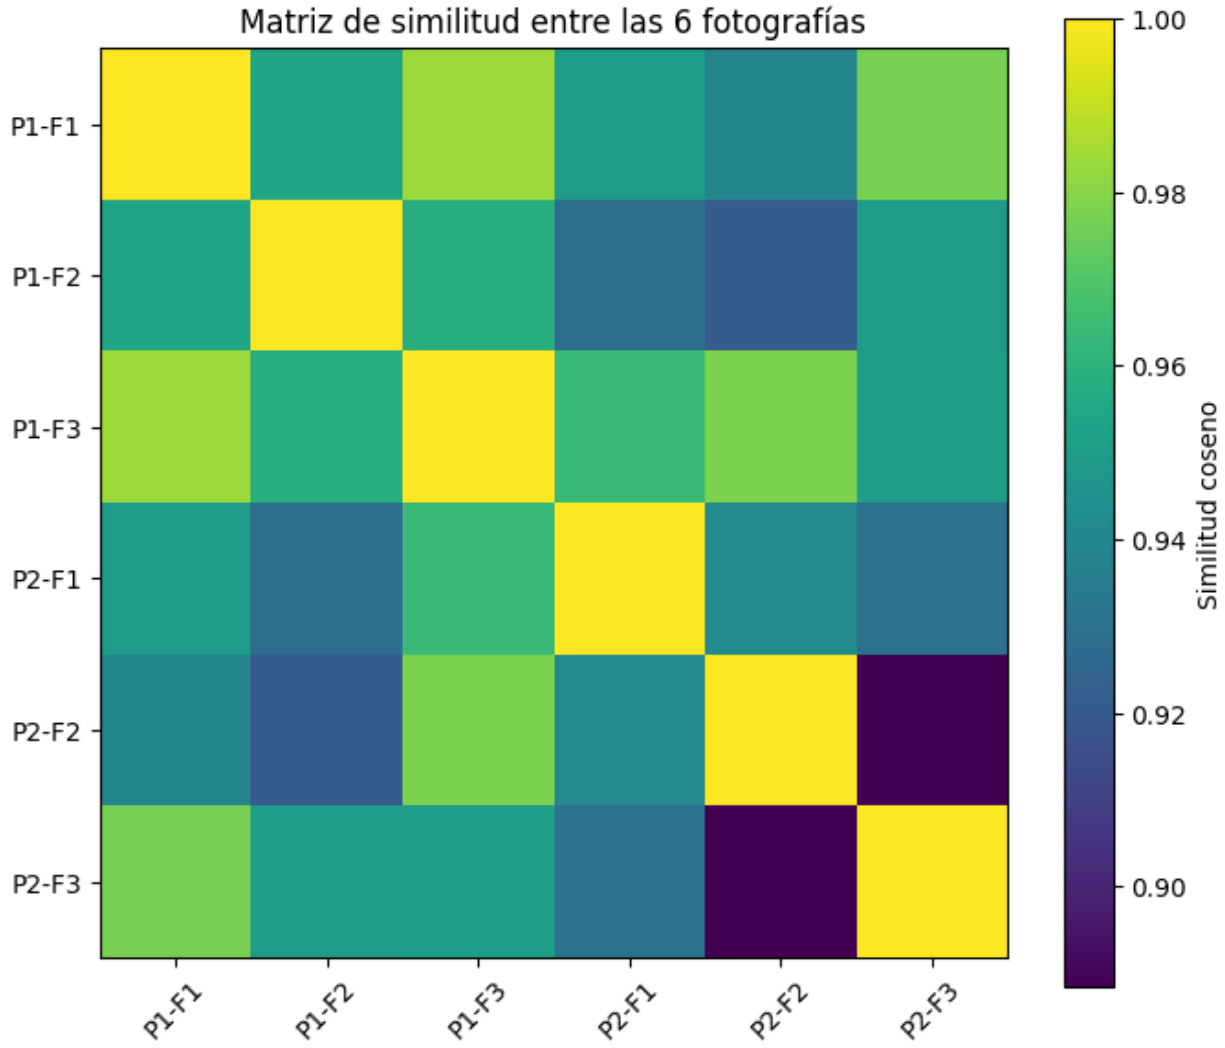
Para la fotografía de Persona 1, la barra correspondiente al prototipo de Persona 2 presentó el valor más alto: 0.9857, frente a 0.9823 de su propio prototipo.

Para la fotografía de Persona 2, la barra correspondiente al prototipo de Persona 1 presentó el valor más alto: 0.9744, frente a 0.9232 de su propio prototipo.

Por lo tanto, la gráfica confirma las dos predicciones incorrectas realizadas por el modelo. En ambos casos, la similitud mayor correspondió al prototipo de una persona diferente de la identidad real de la fotografía consultada.



Paso 28. Construir una matriz de similitud de las seis fotografías



La matriz de similitud permite observar las relaciones entre los embeddings de las seis fotografías mediante comparaciones por pares.

Al tratarse de embeddings normalizados, los valores de la diagonal representan la similitud de cada imagen consigo misma, mientras que los demás valores muestran la semejanza entre fotografías diferentes.

La matriz permite identificar qué imágenes presentan mayor similitud entre sí y detectar posibles confusiones entre las identidades.

En mi experimento, los resultados de Few-shot mostraron que las fotografías reservadas no fueron asociadas correctamente con sus respectivos prototipos. Por lo tanto, la matriz debe analizarse considerando esta limitación y no suponiendo que todas las imágenes de una misma persona necesariamente presentan las mayores similitudes entre sí.

Preguntas y respuestas de análisis para el informe

¿La distancia Anchor–Positive fue menor que Anchor–Negative? Explica el resultado con los valores obtenidos.

Sí. En mi experimento, la distancia Anchor–Positive fue de 0.3017, mientras que la distancia Anchor–Negative fue de 0.3176.

Esto significa que la representación de Anchor se encontró ligeramente más cerca de Positive que de Negative. Aunque el resultado cumple la relación esperada, la diferencia de 0.0159 fue pequeña, por lo que considero que la separación obtenida fue limitada.

¿La similitud coseno produjo una interpretación diferente a la distancia euclidiana? ¿Por qué?

No produjo una interpretación diferente en la comparación inicial, porque ambas métricas mostraron una relación favorable.

La distancia euclidiana fue menor para las imágenes de la misma persona, mientras que la similitud coseno fue mayor para esas mismas imágenes.

Sin embargo, los valores de ambas métricas fueron cercanos, lo que indica que la separación entre las representaciones fue reducida. La diferencia se encuentra en la forma de medir la relación entre los vectores: la distancia euclidiana mide su separación, mientras que la similitud coseno compara principalmente la dirección de sus representaciones.

¿Qué fotografía resultó más difícil de clasificar y qué características visuales podrían explicarlo?

Las dos fotografías de prueba presentaron dificultades porque ambas fueron clasificadas incorrectamente.

Sin embargo, la fotografía correspondiente a Persona 1 presentó una diferencia especialmente pequeña entre las similitudes de los dos prototipos: 0.0034. Esto indica que el modelo tuvo una ambigüedad considerable al comparar esa fotografía.

En el caso de Persona 2, la similitud con el prototipo incorrecto fue superior por 0.0512, lo que evidencia una confusión más marcada.

Entre las posibles causas visuales se encuentran las diferencias de iluminación, posición del rostro, distancia de captura, encuadre, calidad de la imagen y características del fondo. No obstante, los valores numéricos por sí solos no permiten determinar cuál de estas condiciones estuvo presente en cada fotografía; para confirmarlo es necesario revisar las imágenes originales y preprocesadas.

¿La prueba Few-shot mejoró la decisión frente a comparar solo un Anchor con un Positive y un Negative?

No se observó una mejora suficiente en la clasificación Few-shot de las fotografías reales. En la comparación inicial, la distancia euclidiana y la similitud coseno presentaron un orden favorable, lo que indicaba que Anchor estaba ligeramente más cerca de Positive que de Negative. Sin embargo, al construir los prototipos con dos fotografías por persona y evaluar las imágenes reservadas, ambas fueron clasificadas incorrectamente.

Esto demuestra que una comparación favorable entre una tripleta no garantiza que el modelo pueda clasificar correctamente nuevas fotografías. También evidencia que la construcción de prototipos no corrige automáticamente las limitaciones de un encoder que no ha aprendido características suficientemente representativas de las imágenes reales.

¿Qué significa construir un prototipo a partir de dos embeddings?

Significa combinar las representaciones vectoriales de dos fotografías correspondientes a una misma identidad mediante el cálculo de su promedio. El resultado es un vector que resume las características compartidas entre ambas imágenes. Posteriormente, se aplica normalización L2 para mantener una longitud unitaria. En esta práctica, los prototipos permitieron representar matemáticamente a cada persona utilizando dos fotografías de referencia, en lugar de depender de una sola captura.

¿Por qué una precisión de 100 % con solo dos consultas no demuestra que el sistema sea confiable en el mundo real?

Una precisión del 100 % con solamente dos consultas no demuestra confiabilidad porque el conjunto de prueba es demasiado pequeño para evaluar adecuadamente el comportamiento general del modelo.

Con dos fotografías, cada clasificación representa el 50 % del resultado total. Por lo tanto, una sola predicción incorrecta puede modificar considerablemente el porcentaje de precisión. Además, un sistema real debe evaluarse con una mayor cantidad de personas, fotografías y condiciones de captura diferentes. También debe considerar variaciones de iluminación, posición, calidad de imagen y otros factores que pueden afectar las representaciones.

En mi caso, el resultado fue de 0 %, lo que refuerza la importancia de realizar evaluaciones más amplias y no asumir que el modelo es confiable únicamente por los resultados obtenidos con datos sintéticos.

¿Qué efecto puede tener que el encoder haya sido entrenado con rostros sintéticos y probado con fotografías reales?

Puede producir una diferencia de dominio entre los datos de entrenamiento y los datos de evaluación.

Los rostros sintéticos utilizados durante el entrenamiento presentan características visuales controladas y simplificadas, mientras que las fotografías reales contienen texturas, iluminación, fondos, variaciones de posición y características propias de las cámaras.

Como consecuencia, el encoder puede aprender representaciones que funcionan adecuadamente con imágenes sintéticas, pero que no son suficientemente representativas cuando se utilizan fotografías reales. Considero que esta diferencia de dominio es una de las principales causas que deben analizarse para explicar los errores obtenidos en la clasificación Few-shot.

Propón dos mejoras concretas para un experimento posterior.

Propongo las siguientes mejoras:

Entrenar o ajustar el encoder con fotografías reales autorizadas y representativas. Esto permitiría que la red aprenda características visuales más cercanas a las condiciones en las que posteriormente será evaluada. Se deben utilizar conjuntos de entrenamiento y prueba separados para evitar que las mismas fotografías participen en ambos procesos.

Ampliar y diversificar el conjunto de fotografías. Utilizar más imágenes por persona, con variaciones moderadas de iluminación, posición y distancia de captura, permitiría construir prototipos más representativos y evaluar la estabilidad de las comparaciones.

Adicionalmente, considero conveniente probar diferentes combinaciones de Anchor, Positive y Negative, registrando los resultados sin modificar manualmente las etiquetas ni los valores obtenidos.

CONCLUSIONES

Las imágenes reales facilitaron la identificación de las limitaciones inherentes al desplegar un modelo entrenado con datos sintéticos en un dominio diferente. Si bien la evaluación preliminar basada en distancias y métricas de similitud arrojó resultados favorables, las dos fotografías reservadas para validación fueron catalogadas erróneamente mediante el enfoque few-shot, lo que derivó en una precisión nula (0 %).

Esta práctica me permitió inferir que, aunque el cálculo del promedio de múltiples embeddings es una estrategia válida para generar prototipos representativos, su eficacia está supeditada a la robustez y calidad de las representaciones latentes extraídas por el codificador (encoder). En consecuencia, el uso de múltiples referencias no constituye por sí mismo una garantía de acierto en la clasificación.

Como conclusión principal de esta experiencia, destaco la relevancia de realizar un análisis exhaustivo del desempeño empírico del modelo, prestando especial atención a sus fallas y restricciones. En el ámbito del Deep Learning, la obtención de bajas funciones de pérdida o de métricas óptimas en entornos controlados resulta insuficiente; es imperativo auditar rigurosamente la capacidad de generalización del sistema ante distribuciones de datos heterogéneas y escenarios operativos reales.

ANEXO

A continuación, adjunto el repositorio en GITHUB donde se encuentran el desarrollo de esta actividad.

https://github.com/edwardmoreno18/RedesNeuronales_V